

GRADO: FÍSICA

ASIGNATURA: BIG DATA

FINPLUS ANALITYCS CHALLENGE

OS FENÓMENOS:

MARC OLIVER, JOSE ENRIQUE GARCIA,  
PAU BISQUERT Y EVA SÁNCHEZ

FECHA: 14/12/2025

PROFESOR: JORGE LÓPEZ FRESCO

## Índice

|                                         |   |
|-----------------------------------------|---|
| 1. Esquema general del trabajo          | 4 |
| 2. Roles y responsabilidades del equipo | 5 |
| 3. Planificación del trabajo            | 6 |

## Índice de figuras

1. Cronograma de Trabajo - FinPlus Analytics . . . . . 6

## Índice de tablas

1. Arquitectura del Pipeline de Datos . . . . . 4

## 1. Esquema general del trabajo

El proyecto se estructura bajo una arquitectura de datos por capas, garantizando que el pipeline ETL se ejecute eficientemente con PySpark y Python 3 dentro de un entorno Docker para asegurar la reproducibilidad.

| Etapa                              | Componente Principal    | Herramientas            | Propósito y Resultado                                                                         |
|------------------------------------|-------------------------|-------------------------|-----------------------------------------------------------------------------------------------|
| <b>Ingesta</b> ( <i>RAW</i> )      | Datos Fuente            | CSV y Parquet           | Lectura de los archivos originales sin modificación.                                          |
| <b>Procesamiento</b>               | Motor ETL               | <b>PySpark</b> (Docker) | Ejecución del pipeline ETL completo (limpieza, unión, validación) en un entorno reproducible. |
| <b>Análisis</b> ( <i>Curated</i> ) | Scripts de Análisis     | PySpark, VS Code        | Creación de <b>KPIs</b> (Valor, Riesgo, Actividad) y la tabla de segmentación final.          |
| <b>Almacenamiento</b>              | <i>Datasets</i> Finales | Archivos CSV            | Guardado de los datos enriquecidos y agregados en la carpeta <i>/data/curated/</i> .          |
| <b>Visualización</b>               | Dashboard Ejecutivo     | Tableau                 | Presentación interactiva de KPIs e <i>insights</i> de negocio para la dirección de FinPlus.   |
| <b>Control Versiones</b>           | Repositorio Central     | <b>GitHub</b>           | Gestión de código, documentación y trazabilidad de la colaboración en equipo.                 |

Tabla 1: Arquitectura del Pipeline de Datos

## 2. Roles y responsabilidades del equipo

Los roles del equipo, aunque flexibles, se han dividido para asignar responsabilidades clave en el flujo end-to-end del proyecto:

**Eva Sánchez Primo** → *Tech Lead*

- **Funciones:** Responsable de la arquitectura de la solución, la supervisión de la calidad del código, la configuración del entorno Docker y la gestión del repositorio GitHub. Asegura que el pipeline PySpark se ejecute de manera óptima.

**Marc Oliver del Horno** → *Data Engineer*

- **Funciones:** Encargado de la implementación del pipeline ETL en PySpark. Se centra en la ingesta, la limpieza de datos, el manejo de errores, la transformación y la carga final de los datasets curados.

**José Enrique García Garay** → *Data Visualization Expert*

- **Funciones:** Responsable de la capa de comunicación y el diseño del documento de presentación. Define las métricas y visualizaciones necesarias para transmitir los insights de negocio de forma clara a la dirección.

**Pau Bisquert Sala** → *Data Analyst*

- **Funciones:** Lidera el Análisis de Comportamiento (Fase 4). Es responsable de la generación de los KPIs, la creación de la lógica de segmentación y la elaboración de conclusiones para el informe.

### 3. Planificación del trabajo

En el siguiente diagrama de Gant podemos ver cual ha sido nuestra planificación puesto que teniamos 1 mes para realizar el trabajo:




Figura 1: Cronograma de Trabajo - FinPlus Analytics